

Inferencia Estadística: Teoría

Daniel Monjas Miguélez

16 de enero de 2022

Índice

1. Introducción a la Inferencia Estadística. Estadísticos muestrales.	3
1.1. Muestra Aleatoria Simple	3
1.2. Función de distribución muestral	3
1.3. Estadístico muestral	5
2. Distribuciones en el muestreo de poblaciones normales.	7
2.1. Distribuciones χ^2 de Pearson, t de Student y F de Snedecor. . .	7
2.1.1. Distribución χ^2 de Pearson	7
2.1.2. Distribución t de Student	8
2.1.3. Distribución F de Snedecor	9
2.2. Muestreo en poblaciones normales	9
2.2.1. Muestreo en una población normal unidimensional . . .	9
2.2.2. Muestreo en dos poblaciones normales unidimensionales .	10

1. Introducción a la Inferencia Estadística. Estadísticos muestrales.

1.1. Muestra Aleatoria Simple

Definición: Una muestra aleatoria simple (de tamaño n) de una variable X es un vector (X_1, \dots, X_n) formado por n variables aleatorias independientes, todas con la misma distribución que X .

- **Realización muestral:** Cada valor (x_1, \dots, x_n) obtenido al observar (X_1, \dots, X_n) .
- **Espacio muestral (χ^n):** Conjunto de todas las posibles realizaciones muestrales según nuestro conocimiento de P_X (valores de (X_1, \dots, X_n) bajo alguna distribución de la familia):

$$\chi_\theta = \{x/f_\theta(x) > 0\} \rightarrow \text{valores de } X \text{ bajo } P_\theta$$

$$\chi = \bigcup_{\theta \in \Theta} \chi_\theta \rightarrow \text{valores de } X \text{ bajo } \mathcal{P}$$

$$\chi^n = \chi \times \chi \times \dots \times \chi = \{(x_1, \dots, x_n); x_1, \dots, x_n \in \chi\}$$

1.2. Función de distribución muestral

Definición: Sea (X_1, \dots, X_n) una muestra aleatoria simple de una variable aleatoria X con función de distribución F_X . Se define la función de distribución muestral, F_{X_1, \dots, X_n}^* , como una función sobre \mathbb{R} dada por,

$$F_{X_1, \dots, X_n}^*(x) = \frac{n \text{ de variables } X_i \leq x}{n} = \frac{\sum_{i=1}^n I_{(-\infty, x]}(X_i)}{n}, \quad \forall x \in \mathbb{R}$$

Propiedades de la función de distribución muestral:

1. $\forall x \in \mathbb{R}$, $F_{X_1, \dots, X_n}^*(x)$ es una variable aleatoria tal que $nF_{X_1, \dots, X_n}^*(x) \rightsquigarrow B(n, F(x))$:

$$E[F_{X_1, \dots, X_n}^*(x)] = F(x), \quad \text{Var}[F_{X_1, \dots, X_n}^*(x)] = \frac{F(x)(1 - F(x))}{n}$$

2. Si n es grande, y la distribución binomial poco manejable, puede aproximarse por una normal según el Teorema límite de Lèvy:

$$F_{X_1, \dots, X_n}^*(x) \rightsquigarrow \mathcal{N}\left(F(x), \frac{F(x)(1 - F(x))}{n}\right)$$

Demostración:

1. Se tiene que:

$$\begin{aligned} I_{(-\infty, x]}(X_i) &\rightsquigarrow B(1, F(x)) \Rightarrow \sum_{i=1}^n I_{(-\infty, x]}(X_i) \rightsquigarrow B(n, F(x)) \Rightarrow \\ &\Rightarrow nF_{X_1, \dots, X_n}^*(x) \rightsquigarrow B(n, F(x)) \end{aligned}$$

Teniendo en cuenta la linealidad de la esperanza:

$$\begin{aligned} E[nF_{X_1, \dots, X_n}^*(x)] &= nF(x) \Rightarrow nE[F_{X_1, \dots, X_n}^*(x)] = nF(x) \Rightarrow \\ &\Rightarrow E[F_{X_1, \dots, X_n}^*(x)] = F(x) \end{aligned}$$

Por otro lado, puesto que $Var[nX] = n^2 Var[X]$:

$$\begin{aligned} Var[nF_{X_1, \dots, X_n}^*(x)] &= n^2 Var[F_{X_1, \dots, X_n}^*(x)] = nF(x)(1 - F(x)) \Rightarrow \\ &\Rightarrow Var[F_{X_1, \dots, X_n}^*(x)] = \frac{F(x)(1 - F(x))}{n} \end{aligned}$$

2. Como $nF_{X_1, \dots, X_n}^*(x)$ es usma de variables aleatorias independientes e idénticamente distribuidas, el Teorema Central del Límite permite afirmar que, cuando $n \rightarrow +\infty$,

$$\frac{nF_{X_1, \dots, X_n}^*(x) - nF(x)}{\sqrt{nF(x)(1 - F(x))}} = \sqrt{n} \frac{F_{X_1, \dots, X_n}^*(x) - F(x)}{\sqrt{F(x)(1 - F(x))}} \rightsquigarrow \mathcal{N}(0, 1)$$

de manera que, cuando el tamaño muestral es grande, se tiene

$$F_{X_1, \dots, X_n}^*(x) \rightsquigarrow \mathcal{N}\left(F(x), \frac{F(x)(1 - F(x))}{n}\right)$$

Teorema de Glivenko-Cantelli: Sea $\{X_n\}_{n \in \mathbb{N}}$ una sucesión de variables aleatorias independientes e idénticamente distribuidas con función de distribución F_X . Si $F_{X_1, \dots, X_n}^*(x)$ es la función de distribución muestral asociada a la muestra aleatoria simple (X_1, \dots, X_n) de $X \rightsquigarrow P$, se verifica que $F_{X_1, \dots, X_n}^*(x)$ converge casi seguramente y uniformemente a la función de distribución de X , F_X .

$$P \left[\lim_{n \rightarrow +\infty} \sup_{x \in \mathbb{R}} |F_{X_1, \dots, X_n}^*(x) - F(x)| = 0 \right] = 1$$

Es decir, con probabilidad 1, al tomar sucesivas observaciones independientes de la variable y considerar las correspondientes funciones de distribución muestrales, se verifica:

$$\varepsilon > 0, \exists n_\varepsilon / n > n_\varepsilon \Rightarrow F(x) \in (F_{X_1, \dots, X_n}^*(x) - \varepsilon, F_{X_1, \dots, X_n}^*(x) + \varepsilon)$$

1.3. Estadístico muestral

Definición: Dada una muestra aleatoria simple (X_1, \dots, X_n) de X , un estadístico muestral es una función de ella, medible e independiente de cualquier parámetro desconocido; esto es, una transformación $T(X_1, \dots, X_n)$, tal que $T : (\mathbb{R}^n, \mathcal{B}^n) \rightarrow (\mathbb{R}^k, \mathcal{B}^k)$ es medible ($T^{-1}(B) \in \mathcal{B}^n, \forall B \in \mathcal{B}^k$).

Definición: Sea (X_1, \dots, X_n) una muestra aleatoria simple de una variable aleatoria X . La distribución en el muestreo de un estadístico T definido en el espacio muestral $(\mathcal{X}^n, \mathcal{B}^n)$ es la distribución de la variable aleatoria $T(X_1, \dots, X_n)$.

Proposición: La función generatriz de momentos del estadístico media muestral viene dada por:

$$M_{\bar{X}}(t) = (M_X(t/n))^n$$

Demostración: Recordemos que la función generatriz de momentos de una variable aleatoria es aditiva-multiplicativa en el sentido de que la función generatriz de momentos de la suma de n variables aleatorias independientes coincide con el producto de las n funciones generatrices de momentos.

Sea X una variable aleatoria, y (X_1, \dots, X_n) una muestra aleatoria simple de X de tamaño n .

$$\begin{aligned} M_{\bar{X}}(t) &= E \left[e^{t\bar{X}} \right] = E \left[e^{t \frac{\sum X_i}{n}} \right] = E \left[\prod e^{\frac{tX_i}{n}} \right] = \\ &= \prod_{i=1}^n E \left[e^{\frac{t}{n} X_i} \right] = \prod_{i=1}^n M_{X_i}(t/n) = (M_X(t/n))^n \end{aligned}$$

Proposición: La distribución muestral general de los estadísticos de orden, según la variable sea discreta o continua, es:

- X discreta:

$$\begin{aligned} P[X_{(r)} \leq x] &= P[\text{al menos } r \text{ elementos muestrales sean } \leq x] = \\ &= \sum_{i=r}^n \binom{n}{i} (P[X \leq x])^i (P[X > x])^{n-i} \end{aligned}$$

- X continua:

$$g_r(x_{(r)}) = \frac{n!}{(r-1)!(n-r)!} [F(x_{(r)})]^{r-1} [1 - F(x_{(r)})]^{n-r} f(x_{(r)})$$

Definición (Momentos muestrales centrados y no centrados): Se definen los momentos centrados y no centrados de una muestra aleatoria simple de tamaño n como:

- Momento no centrado de orden $k \in \mathbb{N} : A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$.

En particular, se tiene $A_1 = \frac{1}{n} \sum_{i=1}^n X_i = \bar{X} = \text{media muestral}$.

- Momentos centrado de orden $k \in \mathbb{N}$: $B_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$.

En particular, se tiene $B_1 = 0$ (por las propiedades de la media de una distribución), y definimos $B_2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2 = \text{Var}[X] = \text{varianza muestral}$.

Proposición: Sea (X_1, \dots, X_n) una muestra aleatoria simple de una variable aleatoria X .

1. Para los momentos no centrados, se tiene:

$$E[A_k] = E[X^k] \quad \text{Var}[A_k] = \frac{1}{n} (E[X^{2k}] - E[X^k]^2)$$

En particular, $E[A_1] = \mu$, $\text{Var}[A_1] = \frac{\sigma^2}{n}$, donde μ y σ^2 son, respectivamente, la media y la varianza poblacional.

2. Para el momento centrado de orden 2, se tiene

$$E[B_2] = \frac{(n-1)\sigma^2}{n}$$

En particular, se verifica $E[S^2] = \sigma^2$, donde $S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$.

A S^2 así definida le llamamos cuasivarianza muestral.

Demostración: Mirar apuntes.

Definición (Cuantil Muestral): Para cada $p \in (0, 1)$, el cuantil de orden p , c_p , es un valor real tal que

$$F_n^*(c_p) \geq p \quad \text{y} \quad F_n^*(c_p^-) \leq p$$

Se puede expresar de la siguiente forma en función de los elementos de la muestra ordenada:

- Si $np \in \mathbb{N}$, $c_p = \frac{X_{(np)} + X_{(np+1)}}{2}$
- En otro caso, sea $[np]$ la parte entera de np , entonces $cp = X_{([np]+1)}$

Definición (Función generatriz de momentos muestral): Se define la función generatriz de momentos muestral como

$$M^*(t) = \frac{1}{n} \sum_{i=1}^n e^{tX_i}$$

Proposición: La función generatriz de momentos muestral se utiliza para obtener los momentos no centrados, pues se verifica

$$\left. \frac{\partial^k M^*(t)}{\partial t^k} \right|_{t=0} = A_k$$

2. Distribuciones en el muestreo de poblaciones normales.

2.1. Distribuciones χ^2 de Pearson, t de Student y F de Snedecor.

Proposición (Distribución de muestreo de la medida muestral): Si $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$, y (X_1, \dots, X_n) muestra aleatoria simple de X , entonces

$$\bar{X} \rightsquigarrow \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right)$$

2.1.1. Distribución χ^2 de Pearson

Definición (Distribución χ^2 de Pearson): Se dice que una variable aleatoria X tiene una distribución χ^2 de Pearson con n grado de libertad ($n \in \mathbb{N}$), y se denota $X \rightsquigarrow \chi^2(n)$, si su función de densidad de probabilidad es

$$f_X(x) = \frac{1}{\Gamma(n/2) \cdot 2^{n/2}} x^{n/2-1} e^{-x/2}, \quad x > 0$$

La distribución χ^2 de Pearson es un caso particular de la distribución Gamma, $\Gamma(p, a)$, cuya función de densidad es

$$f(x) = \frac{a^p}{\Gamma(p)} x^{p-1} e^{-ax}, \quad x > 0$$

Propiedades (Distribución χ^2 de Pearson):

1. La función generatriz de momentos de una variable aleatoria $X \rightsquigarrow \chi^2(n)$ es

$$M_X(t) = \frac{1}{(1 - 2t)^{n/2}}, \quad t < \frac{1}{2}$$

2. Los momentos no centrados de la distribución $\chi^2(n)$ vienen dados por

$$E[X^k] = 2^k \frac{\Gamma(\frac{n}{2} + k)}{\Gamma(\frac{n}{2})}$$

En particular, $E[X] = n$, $E[X^2] = n^2 + 2n \Rightarrow \text{Var}[X] = E[X^2] - E[X]^2 = 2n$.

3. **Reproductividad.** Si X_1, \dots, X_n son variables aleatorias independientes con $X_i \rightsquigarrow \chi^2(k_i)$, entonces

$$\sum_{i=1}^n X_i \rightsquigarrow \chi^2\left(\sum_{i=1}^n k_i\right)$$

4. **Relación entre las distribuciones χ^2 y $\mathcal{N}(0, 1)$.** Si X_1, \dots, X_n son variables aleatorias independientes e idénticamente distribuidas con distribución común $\mathcal{N}(0, 1)$, entonces:

$$\sum_{i=1}^n X_i^2 \rightsquigarrow \chi^2(n)$$

Observación importante: Para valores de n grandes ($n > 50$, normalmente), se utiliza que su distribución se puede aproximar por una $\mathcal{N}(n, 2n)$, por el teorema central del límite de Lèvy.

Gráfica de la función de densidad de $\chi^2(n)$: Asimétrica a la derecha y unimodal.

2.1.2. Distribución t de Student

Definición: Sean X e Y variables aleatorias independientes con distribuciones $X \rightsquigarrow \mathcal{N}(0, 1)$ e $Y \rightsquigarrow \chi^2(n)$. Entonces la variable aleatoria,

$$\frac{X}{\sqrt{Y/n}}$$

se dice que tiene una distribución t de Student de n grados de libertad, y se denota $T \rightsquigarrow t(n)$.

Propiedades de la distribución t de Student:

1. La función de densidad de probabilidad de una distribución $t(n)$ viene dada por

$$f_T(t) = \frac{\Gamma\left(\frac{n+1}{2}\right)}{\Gamma\left(\frac{n}{2}\right)\sqrt{n\pi}} \left(1 + \frac{t^2}{n}\right)^{-\frac{n+1}{2}}, \quad t \in \mathbb{R}.$$

2. Sea T una variable aleatoria con distribución $t(n)$, con $n > 1$. Entonces, se tiene que existen los momentos no centrados $E[T^r]$ para $r < n$, y se verifica que:

- Si r es impar, entonces $E[T^r] = 0$.
- Si r es par, entonces

$$E[T^r] = \frac{\Gamma\left(\frac{r+1}{2}\right)\Gamma\left(\frac{n-r}{2}\right)}{\Gamma\left(\frac{1}{2}\right)\Gamma\left(\frac{n}{2}\right)}$$

En particular, para $n > 2$, existen los momentos de primer y segundo orden, y se tiene $E[T] = 0$, $E[T^2] = \text{Var}[T] = \frac{n}{n-2}$

Observación importante: Para valores de n grande, se utiliza que la distribución $t(n)$ se puede aproximar por $\mathcal{N}(0, 1)$.

Gráfica de la función de densidad de $t(n)$: La función de densidad de la distribución $t(n)$ cumple que es simétrica y unimodal.

2.1.3. Distribución F de Snedecor

Definición (Distribución F de Snedecor): Sean X e Y variables aleatorias independientes con distribuciones $X \rightsquigarrow \chi^2(m)$ e $Y \rightsquigarrow \chi^2(n)$. Entonces, la variable aleatoria

$$F = \frac{X/m}{Y/n}$$

se dice que tiene una distribución F de Snedecor con (m, n) grados de libertad, y se denota por $F \rightsquigarrow F(m, n)$.

Propiedades de la distribución F de Snedecor:

1. La función de densidad de probabilidad de una distribución $F(m, n)$ viene dada por

$$g(f) = \frac{\Gamma\left(\frac{m+n}{2}\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)} \left(\frac{m}{n}\right)^{m/2} f^{m/2-1} \left(1 + \frac{m}{n}f\right)^{-\frac{m+n}{2}}, \quad f > 0$$

2. Sea F una variable aleatoria con distribución $F(m, n)$. Entonces, se verifica que

$$E[F^r] = \left(\frac{n}{m}\right)^r \frac{\Gamma\left(\frac{m}{2} + r\right)\Gamma\left(\frac{n}{2} - r\right)}{\Gamma\left(\frac{m}{2}\right)\Gamma\left(\frac{n}{2}\right)}, \quad 0 < r < \frac{n}{2}$$

En particular, $E[F] = \frac{n}{n-2}$ si $n > 2$, $E[F^2] = \frac{n^2(m+2)}{m(n-4)(n-2)}$ si $n > 4$, luego se tiene que $Var[F] = \frac{n^2(2m+2n-4)}{m(n-2)^2(n-4)}$ si $n > 4$.

3. Se verifican las siguientes propiedades:

- $F \rightsquigarrow F(m, n) \Leftrightarrow F^{-1} \rightsquigarrow F(n, m)$
- $T \rightsquigarrow t(n) \Leftrightarrow T^2 \rightsquigarrow F(1, n)$

Gráfica de la función de densidad de $F(m, n)$: Es asimétrica a la derecha y unimodal.

2.2. Muestreo en poblaciones normales

2.2.1. Muestreo en una población normal unidimensional

Teorema: Sea (X_1, \dots, X_n) una muestra aleatoria simple de una variable aleatoria $X \rightsquigarrow \mathcal{N}(\mu, \sigma^2)$. Entonces, \bar{X} y $(X_1 - \bar{X}, \dots, X_n - \bar{X})$ son independientes.

Corolario: Bajo las mismas condiciones del teorema anterior, se tiene:

1. $\bar{X} \rightsquigarrow \mathcal{N}(\mu, \frac{\sigma^2}{n})$
2. **Lema de Fisher.** \bar{X} y S^2 son independientes.
3. $\frac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(n-1)$
4. $\frac{\bar{X}-\mu}{S/\sqrt{n}} \rightsquigarrow t(n-1)$

Estadísticos para hacer inferencia sobre los parámetros de una población unidimensional en diferentes situaciones:

- Inferencia sobre μ :

$$\begin{aligned} \sigma_0^2 \quad \text{conocida} : \quad & \frac{\bar{X} - \mu}{\sigma_0/\sqrt{n}} \rightsquigarrow \mathcal{N}(0, 1) \\ \sigma^2 \quad \text{desconocida} : \quad & \frac{\bar{X} - \mu}{S/\sqrt{n}} \rightsquigarrow t(n-1) \end{aligned}$$

- Inferencia sobre σ^2 :

$$\begin{aligned} \mu_0 \quad \text{conocida} : \quad & \frac{\sum_{i=1}^n (X_i - \mu_0)^2}{\sigma^2} \rightsquigarrow \chi^2(n) \\ \mu \quad \text{desconocida} : \quad & \frac{(n-1)S^2}{\sigma^2} \rightsquigarrow \chi^2(n-1) \end{aligned}$$

2.2.2. Muestreo en dos poblaciones normales unidimensionales

Proposición:

$$\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \rightsquigarrow \mathcal{N}(0, 1)$$

Lema extendido de Fisher: Los vectores (\bar{X}, \bar{Y}) y (S_1^2, S_2^2) son independientes.

Estadísticos para hacer inferencia sobre los parámetros de dos poblaciones normales unidimensionales en los siguientes casos:

- Inferencia sobre $\mu_1 - \mu_2$:

$$\begin{aligned} \sigma_1^2, \sigma_2^2 \quad \text{conocidas} : \quad & \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \rightsquigarrow \mathcal{N}(0, 1) \\ \sigma_1^2 = \sigma_2^2 = \sigma^2 \quad \text{desconocidas} : \quad & \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{(n_1-1)S_1^2 + (n_2-1)S_2^2}} \sqrt{\frac{n_1+n_2-2}{\frac{1}{n_1} + \frac{1}{n_2}}} \rightsquigarrow t(n_1+n_2-2) \end{aligned}$$

- Inferencia sobre $\frac{\sigma_2^2}{\sigma_1^2}$:

$$\begin{aligned} \mu_1, \mu_2 \quad \text{conocidas} : \quad & \frac{n_2}{n_1} \frac{\sigma_2^2}{\sigma_1^2} \frac{\sum_{i=1}^{n_1} (X_i - \mu_1)^2}{\sum_{i=1}^{n_2} (Y_i - \mu_2)^2} \rightsquigarrow F(n_1, n_2) \\ \mu_1, \mu_2, \quad \text{desconocidas} : \quad & \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_1^2} \rightsquigarrow F(n_1 - 1, n_2 - 1) \end{aligned}$$